K-Means

Nicolás Kossacoff

Octubre 2024

1. Introducción

K-means es un método estadístico que busca clasificar observaciones en grupos (i.e., clusters) mutuamente excluyentes. El objetivo final es que al comparar observaciones dentro de un cluster, las observaciones sean muy parecidas entre sí, pero si comparamos esas mismas observaciones con las de otros clusters, no.

1.1. Definición de clusters

Definimos a nuestro conjunto de datos como $D = \{X_1, \ldots, X_n\}$ y a $\mathcal{C} = \{C_1, \ldots, C_K\}$ como una partición de D. Cada sub-conjunto de la partición $\mathcal{C}$ es lo que llamamos **cluster**.

En cada cluster queremos tener observaciones que sean lo más similares posibles. Para eso, definimos la **dispersión intra-grupo** como:

$$W(C_k) = \frac{1}{2N} \sum_{j=1}^{n} \sum_{i=1}^{n} ||X_i - X_j||_2^2 \tag{1}$$

la cual calcula la distancia promedio entre las observaciones de un cluster. Nos da una idea de que tan parecidas son las observaciones dentro de cada cluster.

Podemos reescribir la Ecuación (1) como la suma de las distancias entre las observaciones y el centro del cluster. Entonces:

$$W(C_k) = \frac{1}{2N} \sum_{j=1}^{n} \sum_{i=1}^{n} ||X_i - X_j||_2^2 = \sum_{i=1}^{n} ||X_i - \bar{X}_k||_2^2 \tag{2}$$

donde $\bar{X}_k$ es un vector de largo p con la media de cada una de las p features.

Finalmente, definimos la **dispersión total intra-grupos** como:

$$W(\mathcal{C}) = \sum_{k=1}^{K} W(C_k) \tag{3}$$

Nos permite medir que tan compactos son los clusters obtenidos (i.e., que tan buenos son para segmentar observaciones).

1.2. Definición de distancia

Como podemos observar en la sección anterior, cómo calculamos la distancia entre las observaciones es muy importante, ya que define qué significa que dos observaciones sean similares, además de que determina la forma y tamaño de nuestros clusters.

La medida de distancia óptima es la que mejor se adapte al problema en cuestión. Por ejemplo, en las anteriores ecuaciones utilizamos la distancia Euclídea, la cual es una buena elección si nuestros datos siguen una distribución aproximadamente normal. Si nuestros datos no estuviesen normalmente distribuidos, o hubiesen outliers en nuestra muestra, utilizar la distancia Euclídea no es la mejor opción, y otras medidas de distancia como la distancia Manhattan, Minkowski o Coseno son preferidas[1].

2. Algoritmo

La idea original de K-means es la de encontrar la partición $\mathcal{C}$ que minimiza la dispersión total intra-grupo:

$$\min_{C_1,\ldots,C_k} \sum_{k=1}^{K} W\left(C_k\right) \tag{4}$$

Tal como se puede apreciar en la Figura 1, cuanto más compactos sean los clusters (i.e., cuanto más cerca del centro estén las observaciones) mejor.

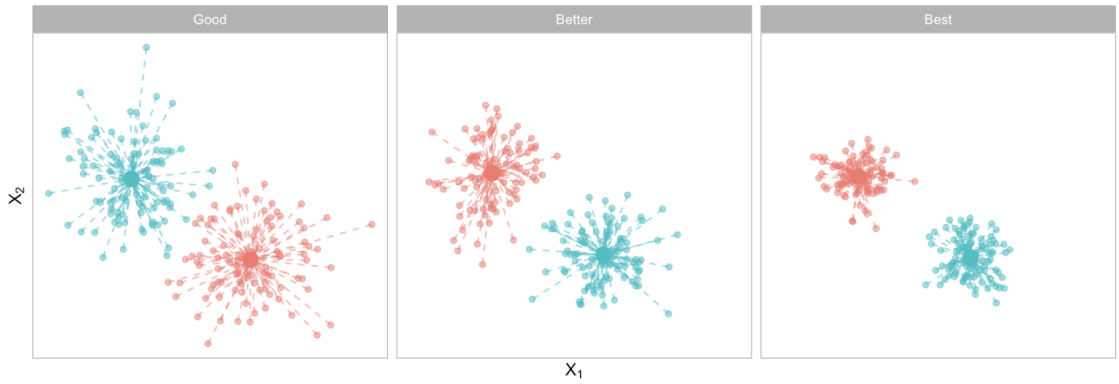

Figura 1: Diferentes soluciones del algoritmo K-means según la distancia intra-grupo que se alcanza.

Ahora, el problema es que tendríamos que buscar todos los posibles clusters y calcular la distancias intra-grupo para cada uno de ellos. Este es un problema computacionalmente muy costoso. La cantidad de formas en las que se pueden agrupar n observaciones en K clusters depende de cuantas particiones no vacías se pueden obtener para un mismo conjunto (hay aproximadamente k^n posibles particiones), lo

[1] Detalle a tener en cuenta: si la medida de distancia que utilizamos no es la distancia Euclídea, entonces el método estadístico no se llama K-Means sino K-Medoids, el cual es una generalización del primero.

que a su vez está relacionado con los números de Stirling. Ese número crece exponencialmente con la cantidad de observaciones, n, y con la cantidad de features, k. Por lo tanto, incluso con valores chicos de n y de k, el costo computacional es muy alto.

2.1. Solución local

Debido al costo computacional que implica calcular todos los posibles clusters, el algoritmo de K-means se concentra en **soluciones locales**.

Esto quiere decir que comienza eligiendo, aleatoriamente, K observaciones para utilizar como centros de los clusters iniciales. Luego, para cada observación, calcula la distancia entre la observación y cada uno de los centros, y la asigna al cluster con el centro más cercano. Ya con los nuevos clusters armados vuelve a calcular los centros y las distancias, asignando nuevamente las observaciones a los clusters con los centros más cercanos. Este procedimiento se repite hasta que la solución converge, es decir, hasta que los clusters no cambian de un paso a otro.

Debido a la aleatoriedad al elegir las K observaciones iniciales, los resultados que obtenemos al realizar este procedimiento pueden variar significativamente. Es por eso que es recomendable realizar varias iteraciones de este procedimiento y finalmente quedarnos con los clusters que más reduzcan la dispersión total intra-grupo, $W(C_k)$.

En resumen, el algoritmo se puede resumir de la siguiente manera:

1. Elegimos la cantidad de clusters, K.
2. Elegimos aleatoriamente K observaciones, las cuales utilizamos como los centros de los clusters iniciales, $\{C_1, \ldots, C_K\}$.
3. Para cada observación $i \in \{1, \ldots, n\}$, calculamos la distancia respecto a cada uno de los centros, y la asignamos al cluster con el centro más cercano. Es decir:
$$i \in C_l \text{ si } ||X_i - \bar{X}_l||_2^2 = \arg \min_{1 \leq k \leq K} ||X_i - \bar{X}_k||_2^2 \tag{5}$$
En este paso obtenemos los nuevos clusters, $\mathcal{C}' = \{C'_1, \ldots, C'_K\}$.
4. Calculamos los centros de los nuevos clusters, $\{\bar{X}_1, \ldots, \bar{X}_K\}$, y la dispersión total intra-grupo, $W(\mathcal{C}')$.
5. Repetimos los pasos (3) y (4) hasta que el algoritmo converge, es decir, los resultados no cambian de un paso a otro.